

계좌 거래 날짜 논리 분석

모듈 2 금융 미니프로젝트 보고서 | 1조

1 분석 목적과 핵심 결론

고객의 가입일, 계좌 개설일, 거래일시가 시간 순서상 일관되는지 검증했다. 거래 패턴을 분석하기 전에 기초 날짜의 신뢰성을 확인해야 거래 기간, 신규 고객 활동, 계좌 이용 실적을 잘못 해석하는 일을 줄일 수 있기 때문이다.

거래 300건 중 289건(96.33%)이 계좌 개설 전 거래였다. 이를 제외한 11건도 고객 가입일보다 계좌 개설일이 앞섰다. 가입일을 최초 고객 등록일로 보는 전제에서는 두 날짜 규칙을 모두 충족하는 거래가 0건이므로, 고객 행동에 대한 결론보다 원천 데이터와 날짜 정의의 재검증이 우선이다.

핵심 지표	결과	해석
개설 전 거래	289 / 300건 96.33%	거래일시가 개설일보다 빠름
가입 전 개설 관련 거래	137 / 300건 45.67%	독립 규칙으로 집계한 거래 수
두 규칙 동시 위반	126 / 300건 42.00%	개설 전 거래이면서 가입 전 개설
두 규칙 모두 충족	0 / 300건 0.00%	정의 확인 전 정상 거래로 활용 곤란

분석 질문과 선택 이유

질문 1. 계좌 개설 이전 거래는 얼마나 많은가? 계좌가 존재하기 전의 거래가 포함되면 계좌별 활동 기간과 거래 빈도가 왜곡될 수 있으므로 우선 점검했다.

질문 2. 고객 가입 이전 계좌 개설은 얼마나 많고 오류는 중복되는가? 고객과 계좌의 연결뿐 아니라 시간 순서도 맞는지 확인하고, 우선순위 분류에 가려진 오류를 파악하기 위해 선택했다.

질문 3. 오류 거래를 걸러낸 결과를 업무 분석에 사용할 수 있는가? 필터링 후 표본과 금액이 얼마나 남는지 확인해 정제 결과의 활용 가능성을 판단했다.

자료: 첨부 ZIP의 CSV 4개. 교육용 합성 데이터이며 외부 시장자료나 실제 고객 정보를 사용하지 않았다.

2 데이터 구조와 처리 방법

제공 파일	규모	사용 범위
transaction_date_classification.csv	300행 · 15열	거래 단위 날짜 재검증의 기준
kaggle_transactions_clean.csv	11행 · 13열	기존 필터 결과와 거래번호 대조
date_classification_summary.csv	4행 · 3열	기존 우선순위 분류와 대조
account_date_summary.csv	2행 · 3열	455개 계좌의 제공 집계 참고

거래 파일의 고유 계좌는 224개, 고유 고객은 156명이다. 거래번호 중복은 0건이고, 동일 계좌에서 고객번호 또는 개설일이 서로 다른 사례는 없었다. 날짜 3개 열은 모두 변환 가능했으며, 금액은 8건(2.67%)이 결측이었다. 금액 결측 8건은 모두 개설 전 거래에 포함된다.

정제 및 결합 방법을 선택한 이유

날짜는 Pandas의 `to_datetime(errors="coerce")`으로 변환했다. 문자열 비교의 위험을 줄이고 변환 실패를 별도로 드러내기 위해서다. 거래금액에서 달러 기호와 쉼표를 제거한 뒤 `to_numeric`으로 숫자화했으며, 기존 숫자 금액과 일치했다. 결측 금액은 0원 거래와 의미가 다르므로 채우지 않았다.

개설 전 거래와 가입 전 개설을 각각 불리언 열로 만들었다. 원본 행을 삭제하지 않아 오류의 규모와 중복을 보존했다. 날짜를 모두 읽을 수 있을 때 가입일 ≤ 개설일 ≤ 거래일시를 정상 순서로 정의했으며 같은 시각은 허용했다.

원래 분류는 판정 불가, 개설 전 거래, 가입 전 개설, 정상 순서의 우선순위를 적용해 재계산했다. 이 결과는 제공된 거래별 분류와 전부 일치했다. 다만 한 거래가 두 규칙을 어길 수 있어 독립 플래그의 교차 집계도 추가했다.

기존 clean 파일은 거래번호로 검증 결과와 left merge했다. `validate="one_to_one"`으로 중복 결합을 방지했고 11건 모두 연결됐다. 원시 고객·계좌·거래 CSV는 없어 최초 결합 과정은 확인하지 못했다. 이번 결합은 제공된 결과 파일 간 대조이다.

집계와 시각화 기준

거래 비율의 분모는 300건, 계좌 요약 비율의 분모는 455개다. 금액 합계와 평균은 결측을 제외하고 계산했다. 날짜 간격은 초 단위 차이를 86,400으로 나눠 일수로 환산했다. 분류별 막대그래프는 오류 규모 비교에, 선행 일수 히스토그램은 시간 차이의 분포 확인에 사용했다.

계좌 잔액은 거래 행에 반복될 수 있어 합산하지 않았다. 제공된 PNG는 보존하고, 이번 검증 수치로 그래프를 다시 생성했다.

3 핵심 발견과 수치 근거

발견 1 개설 전 거래가 대부분을 차지한다

개설 전 거래는 $289 \div 300 \times 100 = 96.33\%$ 다. 거래가 개설일보다 앞선 기간은 최소 2.09일, 중앙값 1,413.53일, 최대 2,543.61일이다. 거래일시는 2019년 1월 1일부터 5월 17일까지인데 계좌 개설일은 2025년 12월 29일까지 분포한다. 단순한 몇 시간의 시차만으로 전체 불일치를 설명하기는 어렵지만, 생성 로직 오류 등 구체적인 원인은 확인할 수 없다.




그림 1 우선순위 분류별 거래 수. Signup order only는 개설 전 거래를 제외한 가입 전 개설 거래를 뜻한다.

발견 2 단일 분류만 보면 중복 오류가 가려진다

독립 규칙 교차 집계	가입 전 개설 해당	가입 전 개설 미해당	합계
개설 전 거래 해당	126건	163건	289건
개설 전 거래 미해당	11건	0건	11건
합계	137건	163건	300건

우선순위 분류에서 가입 전 개설은 11건으로 표시되지만, 이 규칙을 독립적으로 적용하면 $126 + 11 = 137$ 건 (45.67%)이다. 따라서 11건을 전체 가입 전 개설 관련 거래 수로 해석하면 126건을 누락한다.

제공된 계좌 요약에서는 455개 중 202개(44.40%)가 가입 전 개설이고 253개(55.60%)는 가입일 이후 또는 같은 시각에 개설됐다. 이는 거래 단위 137건과 다른 지표다. 455개 원시 계좌가 없어 해당 계좌 집계의 정확성은 독립적으로 재검산하지 못했다.

4 정제 결과의 활용과 업무 제안

발견 3 기존 clean 파일도 추가 검증이 필요하다

구분	거래 건수	금액 확인 건수	확인 가능한 금액 USD
전체	300	292	1,602,017.47
개설 전 거래	289	281	1,551,259.83
개설 전 거래 제외 후	11	11	50,757.64

기존 clean 파일의 거래번호 집합은 개설 전 거래를 제외한 11건과 일치한다. 전체 거래의 3.67%, 확인 가능한 금액의 3.17%만 남지만, 11건 모두 가입 전 개설에 해당한다. 이 파일의 평균 거래금액 4,614.33달러를 전체 고객의 대표적인 거래 규모로 일반화할 근거는 부족하다.

업무 제안

첫째, 데이터 담당자는 가입일이 최초 고객 등록일인지 특정 서비스 가입일인지 확인해야 한다. 정의에 따라 가입 전 개설의 해석이 달라지므로 규칙을 확정된 뒤 검증한다.

둘째, 데이터 생성·적재 담당자는 거래일시, 개설일, 가입일의 생성 범위와 결합 키를 점검한다. 원시 고객·계좌·거래 CSV를 확보해 고객번호 및 계좌번호의 고유성과 참조 무결성을 확인하고, 결합 전후 행 수와 미매칭 건수를 기록한다.

셋째, 분석 담당자는 원본을 보존한 채 오류 거래를 별도 목록으로 관리한다. 금액 결측을 0으로 채우거나 날짜를 임의 수정하지 않는다. 데이터 수정 후 오류율, 금액 결측률, 정상 순서 거래 수를 다시 집계하고 고객별 활동 분석을 재개한다.

분석 한계

교육용 합성 데이터이므로 이 결과는 실제 금융기관의 오류율이나 금융사고를 나타내지 않는다. 금액 합계는 결측 8건을 제외한 거래 규모이며 손실액이 아니다. 입출금 방향 정보도 없어 순현금흐름으로 해석할 수 없다.

원본 노트북과 원시 테이블이 없어 최초 정제·결합 및 455개 계좌 집계는 재현할 수 없다. 첨부 노트북은 제공된 CSV를 이용한 재검증 코드와 실행 결과다. 거래 기간도 제한적이며, 날짜 검증을 모두 통과한 비교 표본이 없어 고객군별 행동 차이나 장기 추세는 분석하지 않았다.

최종 판단 현재 자료에서 우선 수행할 업무는 날짜 정의와 원천 데이터의 확인이다. 오류를 제외했다는 이유만으로 결과를 정상 데이터로 간주하지 않고, 적용한 모든 규칙의 통과 여부를 함께 확인해야 한다.

재현 자료: 1조_계좌거래날짜논리분석.ipynb 및 분석결과 폴더의 최종_거래날짜검증.csv, 최종_분류별요약.csv, 최종_clean재검증.csv. 비율은 소수 셋째 자리에서 반올림했다.